DOI:10.16565/j.cnki.1006- 7744.2022.06.25

OCR 技术在城建档案文件级著录信息自动获取与校核中的应用

蔡　军　陈欣欣

摘　要　通过对城建档案文件级著录现实问题的分析,提出了 OCR 技术在城建档案文件级著录信息自动获取与校核中的应用方案,利用识别区域模板设计实现档案著录信息的准确定位和类别区分,分别利用 OCR 字典技术和广义城建档案关键词数据库技术完成档案著录信息的两轮修正,实现了城建档案文件级著录信息的自动获取与校核,可为档案信息著录实现数字化提供借鉴。

关键词　OCR　城建档案　著录信息　自动获取与校核　应用

中图分类号　G271　**文献标识码**　A　**收稿日期**　2022- 03- 08

★作者简介:蔡军,葫芦岛市自然资源事务服务中心档案分中心,副研究馆员;陈欣欣,葫芦岛市自然资源事务服务中心档案分中心,副研究馆员。

Application of OCR Technology in Automatic Acquisition and Verification of Document Level Description Information of Urban Construction Archives

Cai Jun, Chen Xinxin

Abstract Through the analysis of the practical problems of document level description of urban construction archives, this paper puts forward the application scheme of OCR technology in the automatic acquisition and verification of document level description information of urban construction archives, realizes the accurate positioning and category differentiation of archives description information by using the design of identification area template, and completes two rounds of correction of archives description information by using OCR dictionary technology and generalized urban construction archives keyword database technology respectively. It realizes the automatic acquisition and verification of document level description information of urban construction archives, which can provide reference for the digitization of archives information description.

Keyword OCR; urban construction archives; description information; automatic acquisition and verification; application

城建档案文件级信息著录(以下统称“档案著录”)是档案全文检索的必要前提，也是档案数字化建设的重要基础,决定了档案信息共享、交换、利用等后续工作的质量和水平。为保证著录质量,预防和纠正档案著录过程中出现不必要的错误,通常采用“两录一校”方式开展档案著录，即安排两个人依据档案原件分别著录同一内容的目录信息，第三个人运用软件对著录结果进行比对,并对照档案原件进行校核更改,最大限度地保证档案著录的准确性。但随着城市建设步伐的不断加快,海量城建档案信息的人工著录存在效率不高、经费支出过多等问题，而计算机信息技术的快速发展为档案著录自动化提供了必要的技术支撑，科学运用现代信息处理技术实现档案著录自动化，已成为档案数字化建设亟待解决的问题。

一、传统档案著录存在的主要问题

1.档案著录效率不高。传统档案“两录一校”,不论是信息著录还是质量检查环节工作，均需要对照档案原件进行,不仅方法落后、效率低下,相关人员还需要反复领取、归还档案,频繁履行档案出入库登记手续,难以适应海量档案信息的著录需求。

2.档案安全保管难度大。传统档案著录方式由于需要反复依据档案原件进行著录和校对，延长了档案在库房外的运转周期，档案在著录使用过程中因外在因素或人为原因导致撕裂损坏现象时有发生，给档案安全保管增添了难度。

3. 档案著录费用居高不下。由于档案著录效率不高、工作进展缓慢,为加快档案著录进度,就需要投入更多的人力、物力,导致档案著录经费支出急剧增加,致使相关单位对档案数字化望而却步，影响了档案数字化工作积极性。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

二、OCR 技术在城建档案著录信息自动获取与校核中的应用方案

OCR（Optical Character Recognition，即光学字符识别），是指运用电子设备（扫描仪或数码相机等）检查纸上打印的字符，通过检测暗、亮的模式确定其形状，然后用字符识别方法将形状翻译成计算机文字的过程。将日臻成熟的 OCR 识别技术在档案著录过程中加以应用，为实现档案著录信息自动获取与智能修正，优化档案著录“两录一校”流程，提高档案著录效率和质量，降低档案著录成本提供了可能。

1.总体方案设计。为有效解决传统档案著录的诸多问题，笔者紧密结合档案数字化工作实际，就如何运用 OCR 技术实现档案著录信息自动提取与校核、优化档案“两录一校”流程进行了积极探索，并在工作实践中形成了具体解决办法和措施。总体方案如图 1 所示。

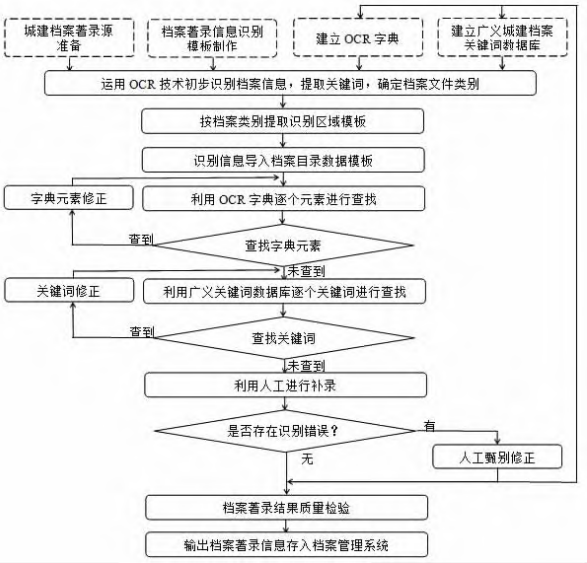

图 1　城建档案著录信息自动获取与智能修正流程图

（1）OCR 信息自动提取替代档案著录“两录一校”的第一录。将档案“两录一校”的第一次著录改为 OCR 自动识别录入，即将处理后的档案数字图像经过 OCR 识别、OCR 字典修正和广义城建档案关键词数据修正后，实现档案著录信息的自动获取。

（2）保留并合理改进档案著录“两录一校”第二录流程。为提高著录质量，继续保留档案“两录一校”第二次手工著录工作环节，即对于已经使用 OCR 文字识别提取技术进行第一轮著录的档案，由著录人员对照档案数字图像采用人工录入的方法，再次对档案著录信息进行一次人工著录。该环节著录工作也由对照档案原件著录改为对照档案数字图像著录，相对节省了时间，提高了效率。

（3）档案著录信息质量校验。对于经过两次著录完成的档案信息，通过计算机自动比对。凡两次著录完全一致的信息，直接导入档案信息管理系统数据库。两次著录信息不完全一致的，提取出不一致的录入项，由校验人对照档案数字图像进行校正，修正后统一录入档案信息管理数据库。

2.具体应用实践。

（1）档案著录准备。①档案著录源数字化加工。用于 OCR 识别的档案著录源应严格按照《纸质档案数字化规范》完成档案数字化加工，分辨率不得低于 300dpi，按标准做好档案数字图像去污、去噪、纠偏、锐化等常规处理工作。鉴于档案数字化加工技术相对规范成熟，此处不多赘述。②档案著录信息识别模板制作。在城建档案领域，不同类别、不同项目的档案中分别保存着项目建设各个阶段的审定表、批文、许可证等档案文件，而同一类别的档案文件目录数据结构相同，在数字图像中的识别区域也完全一致。因此，针对同一类别的档案数字图像通过框选方式分别建立识别区域模板（如图 2 所示）和档案目录数据模板（如表 1 所示），为运用 OCR 技术提取档案著录信息创造条件。③建立 OCR 字典。针对 OCR 识别中常见的文字识别错误，例如“关于”经常被识别为“关干”、“有限公司”经常被识别为“有陨公司”、“日期”经常被识别为“曰期”等，建立 OCR 字典，通过 OCR 字典元素对照，对常见的识别错误进行判定并修正。OCR 字典结构如表 2 所示，其中将每个字典元素设立一个 0—1000 的字典热度值，根据使用的频次动态调整其字典热度值。字典元素按照热度进行降序排列，热度高的排位相应靠前，提升 OCR 字典的修正效率。同时，将 OCR 字典纳入自学习范畴，对于在档案著录过程中涉及的字典元素，动态加入 OCR 字典中，使得 OCR 字典能够动态更新。④建立广义城建档案关键词数据库。在城建档案管理系统、数字化加工环节增设模块，利用关键词提取技术不断收集日常工作中涉及的城建档案关键词，将城建档案领域所涉及的各类审批文件名称、建设单位名称、建设项目名称、设计单位名称、地块名称、地名主管部门批准的标准地名等信息关键词进行积累，建立一个海量城建档案关键词动态数据库。同样，将广义城建档案关键词数据库纳入自学习机

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

制，在运行中进行逐步收集补充，实现广义城建档案关键词数据库的动态迭代更新。

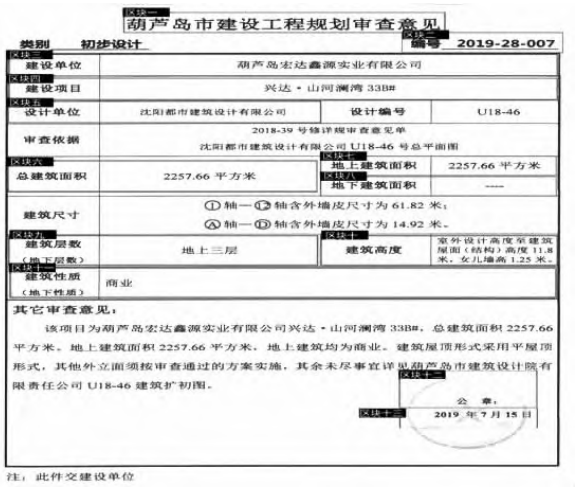
区块一
葫芦岛市建设工程规划审查意见
类别 初步设计 区块二 编号 2019-28-007
区块三 建设单位 葫芦岛宏达鑫源实业有限公司
区块四 建设项目 兴达·山河澜湾 33B#
区块五 设计单位 沈阳都市建筑设计有限公司 设计编号 U18-46
审查依据 2018-39 号修详规审查意见单
沈阳都市建筑设计有限公司 U18-46 号总平面图
区块六 总建筑面积 2257.66 平方米 区块七 地上建筑面积 2257.66 平方米
区块八 地下建筑面积 ----
建筑尺寸 ①轴—⑬轴含外墙皮尺寸为 61.82 米；
Ⓐ轴—Ⓓ轴含外墙皮尺寸为 14.92 米。
区块九 建筑层数（地下层数） 地上三层 区块十 建筑高度 室外设计高度至建筑屋面（结构）高度 11.8 米，女儿墙高 1.25 米。
区块十一 建筑性质（地下性质） 商业
其它审查意见：
该项目为葫芦岛宏达鑫源实业有限公司兴达·山河澜湾 33B#，总建筑面积 2257.66 平方米。地上建筑面积 2257.66 平方米，地上建筑均为商业。建筑屋顶形式采用平屋顶形式，其他外立面须按审查通过的方案实施，其余未尽事宜详见葫芦岛市建筑设计院有限责任公司 U18-46 建筑扩初图。
区块十二 公 章：
区块十三 2019 年 7 月 15 日
注：此件交建设单位

图 2 档案著录信息识别区域模板

表 1 档案目录数据模板

区块名称	预设字段	识别数据内容
区块一	文件题名	
区块二	文件编号	
区块三	建设单位	
区块四	建设项目	
区块五	设计单位	
区块六	总建筑面积	
区块七	地上建筑面积	
区块八	地下建筑面积	
区块九	建筑层数	
区块十	建筑高度	
区块十一	建筑性质	
区块十二	责任者	
区块十三	日期	

表 2 OCR 字典元素对照表

字典元素	对应修正元素	字典热度
关干	关于	982
有陨公司	有限公司	883
曰期	日期	790
……	……	……

表 3 广义城建档案关键词数据库结构表

关键词名称	关键词类别	备注
葫芦岛市建设工程规划审查意见	审批文件名称	
葫芦岛宏达鑫源实业有限公司	建设单位名称	
兴达·山河澜湾 33B#	建设项目名称	
沈阳都市建筑设计有限公司	设计单位名称	
海滨南路 58-8	地名	
葫芦岛市自然资源局	行政主管部门名称	
……	……	

（2）运用 OCR 技术提取档案著录信息。对需要著录编目的档案数字图像，首先利用 OCR 技术进行初步识别，采用关键词提取技术提取有关“许可证”“审查意见”等关键词，判定档案文件类别，与已建立识别区域模板的档案文件类型建立关联后，调取相应的识别区域模板和档案目录数据模板；然后按照识别区域模板设定的识别区域进行 OCR 识别，并把 OCR 识别出的档案著录信息以及其他预先已知的信息填充到档案目录数据模板（如表 1 所示）中。

（3）利用 OCR 字典技术进行档案著录信息第一轮修正。在 OCR 识别结束后，利用 OCR 字典技术实现明显识别错误的修正。将 OCR 字典中的元素逐个在识别结果中进行查找，如果存在一样错误的则更正为正确的。如示例中，文字中有“有陨公司”词语，则全部更正为“有限公司”，“关干”一概更正为“关于”，“曰期”一律更正为“日期”，等等。

（4）运用关键词数据库修正技术实现档案著录信息第二轮修正。将利用 OCR 字典修正技术完成第一轮修正后的档案著录信息，与广义城建档案关键词数据库中的数据进行模糊匹配，如果没有匹配项，则查找匹配度最高的项，如少一个字或多一个字或仅有一个字不同，则直接用关键词进行替换，若匹配度低则保留 OCR 识别结果。例如，建设单位出现葫芦岛市志远建设集团，而经查广义城建档案关键词数据库中建设单位并未出现过此名称，但有葫芦岛市志达建设集团与此高度相似，对此即可作出判断并进行修正。为防止出现误判，二轮修正内容均标注特殊颜色，人工补录环节对此修正内容进行二次确认。

（5）人工补录。通过第一轮、第二轮修正，档案著录信息基本能够得到全面修正。对于个别难以识别并自动修正的信息数据，如手写字、异体字等，需采用人工对照档案数字图像补录方式完成修正。人工修正的内容均由软件系统进行记录，并对 OCR 字典或广义关键词数据库进行动态更新。

（6）质量检验。质量检验即将录入完成的档案著录信息同档案数字图像信息进行复核，全面检查著录信息是否完整、准确、规范，对未发现问题的档案著录信息应及时导入档案信息管理系统，对存在问题的档案著录信息应重新返工修正后导入档案信息管理系统，确保档案著录信息质量符合标准要求。

将 OCR 文字提取与自动校核技术应用于城建档案著录工作，同传统的档案“两录一校”方式相比，具有无法比拟的优势。一是能够全面提高（下转第 107 页）

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

地区的高校都有着与学校建校办学历史密切关联的红色基因可循。各高校档案部门要有意识担当，系统梳理、深入挖掘利用相关红色史料，开展爱党、爱国、爱校思想政治教育工作。

3.以扎实开展党史学习教育为契机，多种方式开发利用红色档案。高校档案部门要以扎实开展党史学习教育为契机，营造校园红色文化氛围。首先，可以通过党史专题讲座、主题教育活动等方式开展关于党的重要领导人诞辰、建党史上的重大事件等党史专题重大纪念活动。其次，在“七一”、国庆节等重大节日开展红色档案宣传活动，通过开展党史档案专题讲座等方式，使广大师生接受党史教育，提升其思想政治素质。再次，在档案馆网站、校史馆陈列室开辟红色档案专栏，展示学校的红色基因，激发广大师生校友的爱党、爱国、爱校情怀。最后，档案部门可以利用网站、微博、博客、微信公众号、抖音号等多种新媒体，向广大师生校友推送、宣传学校红色档案内容，讲述本校独特的红色故事，激发其对学校党史档案、红色档案的兴趣。

党的十九大报告指出，中国特色社会主义文化，源自于中华民族五千多年文明历史所孕育的中华优秀传统文化，熔铸于党领导人民在革命、建设、改革中创造的革命文化和社会主义先进文化，植根于中国特色社会主义伟大实践。高校建校办学史也是中国特色社会主义伟大实践的一部分，高校档案工作者要肩负起自己的历史使命，做好高校红色档案开发利用工作。

参考文献
[1]习近平在河南考察时强调：坚定信心埋头苦干奋勇争先　谱写新时代中原更加出彩的绚丽篇章[N].人民日报，2019-09-19(1).
[2]颜茵.论党史档案在高校思想政治理论课中的运用[J].山西档案，2014(6):78.
[3]林淑铭.浅谈新形势下如何开发利用党史档案资源 不断提升资政育人水平[J].福建党史月刊，2009(10):35.
[4]陆伟华，邓素媛.广西红色档案资源的开发应用研究[J].山西档案，2017(1):85.
[5]徐拥军.挖掘档案价值 读懂百年党史[J].中国档案，2021(3):74.

（上接第 97 页） 档案著录效率。OCR 文字识别速度远远高于人工著录，即使算上前后期的处理环节所花时间，其速度也是人工著录的 3—5 倍。尽管由于档案形成质量影响，OCR 文字识别准确率难以达到 100%，但同大批量人工著录相比，OCR 文字识别质量也明显优于人工著录。二是有效降低了档案安全风险。将 OCR 文字提取技术应用于优化后的“两录一校”流程，无论是著录环节还是校对环节的工作，均可对照档案数字图像进行录入或校对，实现了档案一次扫描 N 次利用，大大缩短了档案库外运转周期，有利于档案安全保密。三是节约了档案著录经费。将 OCR 文字提取与自动校核技术应用于档案著录工作，减轻了档案著录工作负担，节省了大量人力资源，优化了人力资源配置，降低了著录经费支出，确保将有限的资金投入到更有意义的档案数字化其他环节工作中。

参考文献
[1]邱治涵，王嘉豪，李文炜，王东灿.基于 OCR 文字识别技术应用软件的设计与实现[J].电脑知识与技术，2021，17(26):47-49.
[2]马泽. OCR 文字识别技术在不动产数据整合中的应用[D].南昌：东华理工大学，2018.
[3]梁连高.浅析纸质文书档案数字副本 OCR 识别方法[J].科技与创新，2018(4):129-130.
[4]田支斌.普通文书档案数字化扫描工程实践探索[J].黑龙江档案，2017(6):73.
[5]钟子喆，韦军，朱凤印.OCR 汉字识别系统获取纸质图片资料文字信息技巧[J].现代交际，2017(16):191-192+190.
[6]张鹏.基于 OCR 技术的高校数字化档案资源的开发与利用[J].福建电脑，2013，29(5):67-69.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net