基于深度学习的债券图表数据光学字符识别(OCR)检测与文本识别的应用

康雪玮　于文雅　谭钧恺　邓 超　巩红晖　夏 辉*
(沈阳师范大学 软件学院　沈阳　110034)

摘　要:针对诸多业务场景下的海量债券图表数据处理效率低下的问题,本文基于深度学习技术设计应用于债券图表、图文字光学符号识别 OCR(Optical Character Recognition)解决方案。本文通过基于深度学习的技术所设计的债券图表 OCR 的检测和识别方案,能较好地识别图像中的文字如:身份证、校园卡、银行卡、财务报表等,实现不同实际业务场景中的需求,在一定程度上提高日常应用业务场景的智能化处理能力。

关键词:深度学习;　文字检测;　文字识别;　自然语言处理
中图分类号: TP183　　**文献标识码**: B　　**文章编号**: 8024

Application of OCR Detection and Text Recognition of Bond Chart Data Based on Deep Learning

KANG Xuewei　YU Wenya　TAN Junkai　DENG Chao
GONG Honghui　XIA Hui*
(College of Software, Shenyang Normal University　Shenyang　110034)

Abstract: Aiming at the problem of low efficiency in processing massive bond chart data in many business scenarios, this paper designs an Optical Character Recognition (OCR) solution for text recognition of bond charts based on deep learning technology. In this paper, the bond chart OCR detection and recognition program designing based on deep learning technology can identify better to the text information in the image of ID cards, campus cards, bank cards and financial statements, and realize different actual business scenarios. To a certain extent, improve the intelligent processing capabilities of daily application business scenarios.

Keywords: deep learning;　text detection;　text recognition;　natural language processing

0 引言

近年来,图像的光学符号识别(OCR)因其在许多领域的实际应用在计算机视觉领域引起越来越多的关注,OCR 文本识别技术是由文本检测和文本识别两个核心子任务组成。在深度学习技术发展前,传统的 OCR 文本检测传统 OCR 基于图像处理(二值化、连通域分析、投影分析等)和统计机器学习(Adaboot、SVM),提取图片上的文本内容。深度学习的 OCR 主要是指充分运用模型算法的能力,替代传统的人工手动检测方法,自动地检测得出文本的不同类别及其位置的信息,根据所需的位置文本信息,自动地识别与其它位置的文本内容,一般使用到的模型算法主要有:文字检测:DB[2]、EAST[3]、CTPN[4]、RRD[5]等;文字识别:CRNN[6]、StarNet[7]、Rosetta[8]等。

随着近年深度学习的不断发展,基于卷积神经网络的 OCR 技术打破了传统 OCR 技术的框架[1],DB[2]、EAST[3]、CTPN[4]、RRD[5]等基于深度学习的文字检测算法提出在识别率以及准确率上都有质的飞越。CTPN[4]结合 CNN 与 LSTM 深度网络,能有效地检测出复杂场景的横向分布的文字,但在竖直文本或倾斜的文本,该方法的检测就很差。EAST[3]采用 FCN 网络 + Locality-Aware NMS 能有效地解决竖向、倾斜文本的问题,但在较长的文本识别中效果并不好。基于分割的 DB[2]可在分割网络中执行二值化过程,可自适应地设置二值化阈值,不仅简化了后处理,而且提高了文本检测的性能,它的优点在于文字不易被切断且后处理相对简单地能弥补 EAST[3]在长文本中检测的不足,在使用轻量级 Backbone 时,DB[2]表现相当好,因此本文选用 DB[2]作为的文字区域目标检测模型。在文字检测方面,本文采用 CRNN+CTC 的算法框架进行文字识别的检测,CRNN[6]特点是序列特征与卷积特征相融合,CTC 是一种基于 Loss 计算的方法,用 CTC 代替传统的 Softmaxloss 所需的训练样本无须对齐即可实现训练,CTC 损失能解决预测结果和标签不一致的问题,在债券图表中表现较为优秀。

本文通过对 OCR 识别过程进行分析,并基于深度学习的方法设计 OCR 识别方案,着重对债券图表数据搭建的深度学习模型进行训练;最后对所设计的 OCR 方案进行实验验证。实验结果表明,本文方法能有效地把图像数据中的文字信息提取出来,在一定程度上提高日常应用业务场景的智能化处理能力。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

1 基于深度学习的 OCR 设计方案

本文所设计的基于深度学习的债券图表数据 OCR 检测与文本识别的应用方案主要包含四个模块，分别是图像预处理、文本区域目标检测、文字识别、自然语言处理（Natural Language Processing），其流程如图 1 所示。

本系统是基于百度开源的 PaddleOCR[9]开发工具套件，在开源的算法和预训练模型基础上使用自行收集的数据集进行微调最终得到本系统。其中，文字区域目标检测、文字识别是 OCR 识别的核心任务，在图像预处理步骤中文字方向判定使用 Paddle OCR[9]开发工具套件内置的方法分类器来对文字方向进行分类，后处理阶段通过自然语言处理（Natural Language Processing）技术即中文词法分析 –LAC（Lexical Analysis of Chinese）进行切分和匹配提取行识别结果中的关键信息。

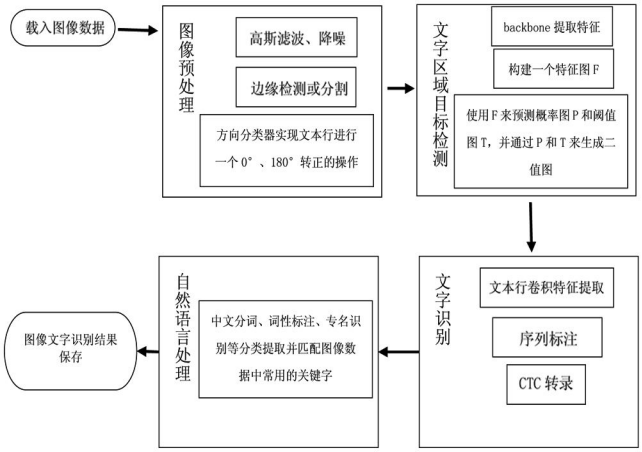

图 1 深度学习 OCR 流程

1.1 图像预处理

在各种业务应用场景中，因为不同的用户或公司在对图像的获取方式并不统一，存在多种未知因素的干扰，因此所获取的图像质量参差不齐，所以在债券图表数据 OCR 检测与文本识别业务系统在 OCR 识别任务开始前首先对需要识别的图像进行预处理操作，在本文中预处理采用去噪处理（高斯降噪）、图像增强、倾斜校正、彩色图像转变成灰度图、灰度图转化成二值图等操作进行图像预处理工作。在日常应用场景中如在银行办理业务时，业务员在办理对文档进行扫描业务的过程中主要经常存在 0°、180° 方向的倾斜问题。因此针对这类业务问题，提出把文本矫正问题转换为分类问题，通过方向分类器 CLS 进行方向分类处理，方便之后文字区域目标检测和文本识别任务的进行。

1.2 文字区域目标检测

文本区域目标检测的目的是定位图像中的文本区域。在债券图表数据 OCR 检测与文本识别业务系统中，使用基于分割的 DB[2]（Differentiable Binarization）作为基于分割网络的文本检测器。首先，图片通过特征金字塔结构的 Resnet50–vd 层（Backbone 特征提取），通过上采样的方式将特征金字塔的输出变换为同一尺寸，并级联（Cascade）产生特征及特征层；然后，通过特征层预测概率图（Probability map）及文本概率图，用于计算该像素属于文本的概率形成文本概率图，然后根据各像素动态阈值形成动态阈值图；最后，通过文本概率图和动态阈值图生成 DB[2]二值图，根据 DB[2]二值图拓展标签生成，形成文本框。DB[2]文字区域检测模式算法网络结构图如图 2 所示。

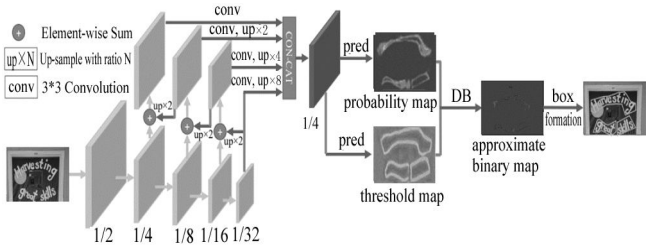

图 2 DB 文字区域目标检测网络结构

1.3 文字识别

在债券图表数据 OCR 检测与文本识别业务系统中，使用 CRNN[6]作为文本识别器，它在文本识别中得到广泛应用。CRNN[6]的结构主要是 CNN+RNN+CTC，它们分别的作用是，使用深度 CNN，对输入图像提取特征，得到特征图。使用双向 RNN（BLSTM）对特征序列进行预测，对序列中的每个特征向量进行学习，并输出预测标签（真实值）分布。使用 CTC Loss，把从循环层获取的一系列标签分布转换成最终的标签序列。CRNN[6]网络结构如图 3 所示。

1.4 识别后的文本处理

在债券图表数据 OCR 检测与文本识别业务系统中，完成文字识别后，对识别后的文字进行自然语言处理，这里采用中文词法分析 –LAC（Lexical Analysis of Chinese）（是一个联合的词法分析模型，能整体性地完成中文分词、词性标注、专名识别任务）进行词性分类标注来处理，从文字识别中选出需要的关键信息保存至后台数据库中（例如从身份证 OCR 识别结果中提取出姓名、出生年月、身份证号等关键信息；校园卡 OCR 识别结果中提取出姓名、学号、学院所对应的具体值，然后直接存储至相应的数据库中），在提取债券图表时，可根据不同类型的财务报表设计相应的识别模板进行匹配。LAC 网络框架为 BiGRU+CRF，整体框架图如图 4 所示。

2 OCR 在债券图表数据中的应用

使用基于深度学习的 OCR 识别技术，实现拍照文字识别、相册图片文字识别和截图文字识别，能更高效、准确、便捷地用于卡、证件、财务报表、笔记、翻译等移动应用中，方便用户进行文本的提取或录入，有效提高处理效率。基于深度学习的债券图表 OCR 检测和识别主要有以下业务场景。

2.1 卡、证件类的识别

身份证、银行卡、行驶证、驾驶证、护照等具有固定格式的图像文字识别技术已较为成熟，在各种大型企业机构中，包括银行、公安机关、保险公司、金融业已成功地应用。特别是由于从传统的机器学习中引入了先进的深度学习技术后，卡、证类的 OCR 识别准确率达到 99%。像身份证、银行卡等这类卡、证据类的 OCR 识别技术在诸多业务场景有广泛的应用，例如：公安机关办理业务、录入身份信息等；

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

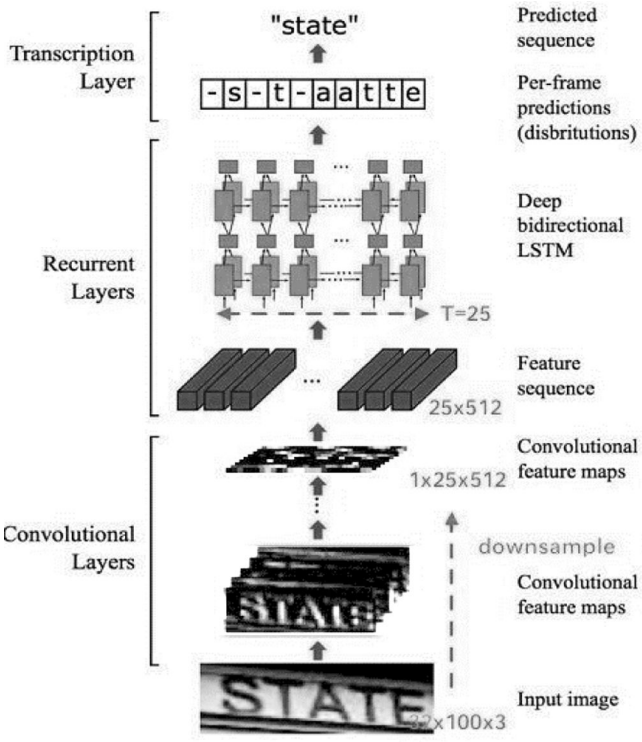

图 3 CRNN 网络结构

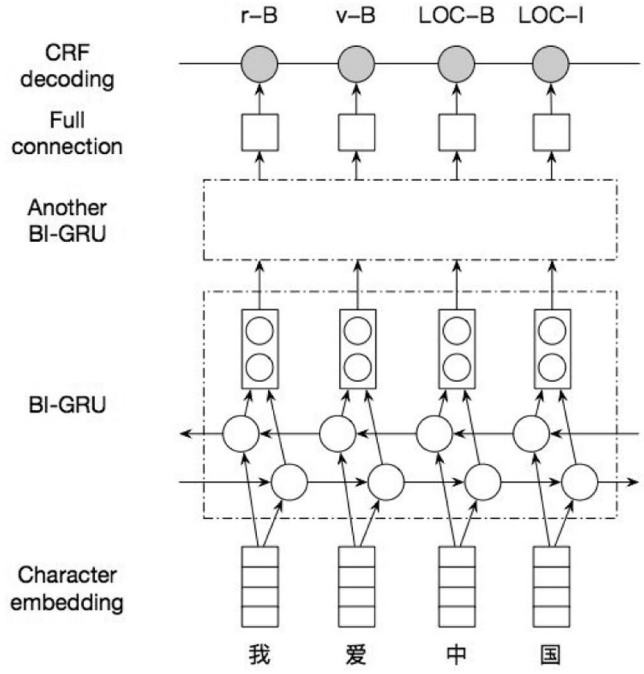

图 4 LAC 网络框架

在银行业的手机银行绑定银行卡、验证身份证等；在保险业的查询保险信息、录入信息等。

2.2 财务报表

财务报表主要包括损益表，所有者权益变动表，损益表，资产负债表和财务报表附注。财务报表有许多不同的类型的表格，财务报表中的表格又主要分为带有表格线的和不带表格线的两种类型。在文字区域检测时，无疑多了主观的噪声，因此需要进行排除这类噪声的干扰。且由于财务报表类型众多，还需要通过 NLP 技术对识别后的文字结果进行分类处理，提取出其中的关键信息，并进行表格模板的精准匹配，以满足各类文字信息的正确识别。

2.3 发票识别

发票管理是整个企业的财务体系中不可忽视的一个组成部分，也是一直令财务人员十分头痛的事。因为采用人工手动录入文档信息的传统方法存在效率低下、时间长、准确度得不到保证等问题，但随着科学信息技术的进步和发展，人工智能这一概念提出，OCR 发票识别等新技术的出现，已给公司财务管理系统指出道路，为财务人员在工作中节省很多时间、提高工作效率。

2.4 其他类型文档

除了以上提到的卡、证类、财务报表类和发票类外，在日常各种业务场景中还包含很多其它类型的图像文档有 OCR 的识别需求。如远程身份认证，结合 OCR 和人脸识别技术，实现对用户身份证件信息的自动识别和录入；同时通过人脸核实身份解决方案进行人脸识别和活体检测，完成用户身份验证，应用于金融保险、社保、电商、O2O 等行业，有效降低用户输入成本，控制业务风险；内容审核使用 OCR 文字识别技术，实现对图像中文字内容的提取，结合文本审核技术识别违规内容，提示相应风险，协助进行违规处理，可应用于电商广告审核、舆情监管等场景，帮助用户有效规避业务风险；另外，基于债券图表数据 OCR 检测与文本识别对各类医疗单据、金融财税票据、法律卷宗等纸质文档的识别，并返回文字在图片中的位置信息以便于进行比对、结构化等处理，为提高文档电子化程度起着非常重要的作用。

3 实验结果分析

3.1 实验配置

实验在百度 AI Studio - 人工智能学习与实训社区进行，采用的深度学习开发框架为 PaddlePaddle，开发语言为 Python，实验硬件信息和软件环境如表 1、表 2 所示。

表 1 单台 AI Studio 高级版硬件信息表

硬件	规格	数量
CPU	4 核	1
内存	32GB	1
显卡	Tesla V100 16GB 显存	1
硬盘	100GB	1

表 2 OCR 识别软件环境

环境搭建	
操作系统	Ubuntu16.04
CUDA	10.1.243
Python	3.7
PaddlePaddle	PaddlePaddle-GPU2.0.2

3.2 实验数据集

3.2.1 训练数据集

文本区域目标检测 DB [2] 模型训练集为 ICDAR2019-LSVT[11]（Large-scale Street View Text with Partial Labeling）中文街景图像数据集，其中包含 5W（2W 测试 +3W 训练）全标注数据（文本坐标 + 文本内容）使用矩形框标注文本行；CRNN[6]模型的训练数据 集是：

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

（1）英文数据集，MJSynth 和 SynthText 合成数据，数据量上千万；

（2）中文数据集，LSVT 街景数据集根据真值将图 Crop 出来，并进行位置校准，总共 30w 张图像。此外基于 LSVT 的语料，合成数据 500W。

3.2.2 测试数据集

通过 Python 爬虫随机爬取 + 自行收集的身份证、银行卡和财务报表等数据和随机选取训练集中 20%作为测试数据集。

3.3 实验结果及分析

本文使用在真实业务场景下收集的身份证、校园卡、银行卡、财务报表附注等图像进行基于深度学习的债券图表数据 OCR 检测与文本识别模型进行推理测试，以检验该系统在真实业务场景中的识别效果。图 5 为方向分类模型对 0° 、180° 旋转图像推理，图像的预测结果（分类的方向和得分）会打印到屏幕上；身份证图像 OCR 识别结果如图 6 所示，分为三行，第一行为未识别的原始身份证图像，第二行使用矩形框的标注的身份证图像为文字区域目标检测推理结果，图像最下面一行为识别结果，暂时以.TXT 文本形式保存识别后的文本信息。图 7 为银行卡、校园卡、财务报表的识别，通过识别的结果来看基本达到实验预期结果，对带表格线的财务报表附注也能达到比较准确的识别。

Predicts of ./doc/imgs_words/ch/word_4.jpg:['0', 0.9999963]

图 5 方向分类模型推理结果

图 6 身份证 OCR 文字识别效果

图 7 校园卡、银行卡、财务报表附注 OCR 文字识别效果

图 5 中，使用 PaddleOCR[9]内置的方向分类器对文字的方向进行分类处理，方便后续的文字区域检测和文字识别。由图 6 与图 7 的检测和识别效果可以看出，推理结果基本达到实验预期，并对识别结果通过中分词法分析处理后提取出来的文字信息，与传统的文字识别不同的是，它能筛选出所需的文字信息，排除其它无用的文本信息，在实际的应用中大大地提高文档录入的效率，在一定程度上提高日常应用业务场景的智能化处理能力。

3.4 性能比较与分析

为验证本文采用的文字区域检测模型与文字识别模型的性能，将 DB[2]和 CRNN[6]模型在 ICDAR2015[10]文本检测公开数据集上与其它主流模型算法进行对比分析，文字检测模型算法效果如表 3 所示。

表 3 文字检测模型对比结果

模型	Precision	Recall	Hmean	FPS
DB[2] (ResNet50)	91.8%	83.2%	87.3%	12 帧/秒
DB[2] (ResNet18)	86.8%	78.4%	82.3%	48 帧/秒
EAST[3]	83.6%	73.5%	78.2%	13.2 帧/秒
CTPN[4]	74.2%	51.6%	60.9%	7.1 帧/秒
RRD[5]	85.6%	79%	82.2%	6.5 帧/秒

从表 3 中可以看出，本文采用的 DB 模型在准确率、召回率和平均精度上均优于文献[3]、文献[4]和文献[5]中的 EAST 、CTPN、RRD 模型，在采用 ResNet50 主干网络时推理速度上稍逊于 EAST 模型，特别的即使用轻量级主干网络（ResNet18）该方法也可在本测试集上达到最高识别准确度，以及最快速的推理速度。

表 4 对比文字识别模型 CRNN [6] 与文献 [7,8] 中的 Rosetta 和 StarNet 模型在使用 MJSynth 和 SynthText 两个文字识别数据集训练，在 IIIT，SVT，IC03，IC13，IC15，SVTP，CUTE 数据集上进行评估。本文基于深度学习的债券图表 OCR 文字检测与识别系统中文字识别模型采用的 CRNN[6]算法，在识别准确度上略优于 Rosetta 和 StarNet 模型算法。文字识别模型算法对比结果如表 4 所示。

表 4 文字识别模型算法对比结果

模型	Avg Accuracy
Rosetta[8]	80.9%
StarNet[7]	81.42%
CRNN[6]	82.76%

4 结论

随着深度学习技术的不断发展，采用 OCR 技术进行信息录入的方法已成为信息录入的重要的方法之一。实验结果表明，本文通过基于深度学习的技术所设计的债券图表 OCR 的检测和识别方案，能较好地识别图像中的文字如：身份证、校园卡、银行卡、财务报表等，实现不同实际业务场景中的需求，在一定程度上提高日常应用业务场景的智能化处理能力。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

在本的工作中,首先对本文的方案进行介绍,然后围绕文字区域目标检测和文字识别问题进行分析,接着对可实际应用到的业务场景进行分析,最后得出较好的推理结果。

参考文献

[1] 王 珂,杨 芳,姜 杉.光学字符识别综述[J].计算机应用研究,2020,37(S2):22-24.
[2] Liao M, Wan Z, Yao C , et al. Real-time Scene Text Detection with Differentiable Binarization[J]. 2019.
[3] Zhou X, Yao C, Wen H, et al. EAST: An Efficient and Accurate Scene Text Detector[J]. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017.
[4] Zhi T, Huang W, Tong H, et al. Detecting Text in Natural Image with Connectionist Text Proposal Network[C].// European Conference on Computer Vision. Springer, Cham, 2016.
[5] Liao M, Zhu Z, Shi B, et al. Rotation-Sensitive RegressionforOrientedSceneText Detection[C].// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2018.
[6] Shi B, Xiang B, Cong Y. An End-to-End Trainable Neural Network for Image-Based Sequence Recognition and Its Application to Scene Text Recognition [J].IEEE Transactions on Pattern Analysis & Machine Intelligence, 2016, 39(11):2298-2304.
[7] Wei L, Chen C, Wong K Y, et al. STAR-Net: A SpaTial Attention Residue Network for Scene Text Recognition[C].// British Machine Vision Conference 2016. 2016.
[8] Borisyuk F, Gordo A, V Sivakumar. Rosetta: Large scale system for text detection and recognition in images[J].
[9] Du Y, Li C, Guo R, et al. PP-OCR: A Practical Ultra Lightweight OCR System[J].2020.
[10] D Karatzas, Gomez-Bigorda L, Nicolaou A, et al. ICDAR 2015 competition on Robust Reading[C].// International Conference on Document Analysis & Recognition. IEEE Computer Society, 2015.
[11] Nayef N, Patel Y, Busta M, et al. ICDAR2019 Robust Reading Challenge on Multi-lingual Scene Text Detection and Recognition - RRC-MLT-2019[C].// 2019 International Conference on Document Analysis and Recognition (ICDAR). IEEE, 2020.

作者简介

康雪玮(2000-),男,汉族,广西柳州人,本科,学生。主要研究方向:深度学习、大数据。
于文雅(2000-),女,汉族,山东青岛人,本科,学生。主要研究方向:机器学习、数据挖掘、分布式计算。
谭钧恺(2002-),男,汉族,黑龙江七台河人,本科,学生。主要研究方向:大数据。
邓 超(2000-),男,壮族,广西南宁人,本科,学生。主要研究方向:智能算法,大数据。
巩红晖(2000-),男,汉族,江苏徐州人,本科,学生。主要研究方向:机器学习。
夏 辉(1979-),男,汉族,河南永城人,硕士研究生,副教授。主要研究方向:智能计算、云计算(本文通讯作者*)。

(上接第 25 页)

4 结论

本文针对小区的用电需求,设计出一种基于物联网技术和数据分析平台的智能能源管理系统,并采用灰狼优化算法对设备用电调度进行管理,提高了用电使用效率,有显著的节能效果、有较高的应用价值。

参考文献

[1] Manic M, Wijayasekara D, Amarasinghe K, et al. Building Energy Management Systems: The Age of Intelligent and Adaptive Buildings[J]. IEEE Industrial Electronics Magazine, 2016, 10(1): 25-39.
[2] Wei C, Li Y. Design of energy consumption monitoring and energy-saving management system of intelligent building based on the Internet of things[C].// International Conference on Electronics, Communications and Control. IEEE, 2011,20(2):3650-3652.
[3] 楼志斌.智能楼宇能耗监控系统的设计与实现[J].计算机应用与软件,2012,29(6):205—208.
[4] 潘婷婷,李军祥,黄芳旧.基于需求响应的含光伏电力系统优化及其算法改进[J].上海理工大学学报,2019,41(05):448-454.
[5] 何后裕,郭健翔,王永利.面向配电网风电消纳的冰蓄冷空调系统多目标优化策略研究[J].电力系统保护与控制,2019,47(23):180-187.
[6] 陈嘉鹏,汤乃云,汤 华.考虑可再生能源利用率的风-光-气-储微能源网经济调度研究[J].可再生能源,2020,38(01):70-75.
[7] G. Matharu, P. Upadhyay, and L. Chaudhary, The Internet of Things: Challenges and security issues[C], in Proc. International Conference on Emerging Technologies (ICET),2015,25(04): 54-59.
[8] J B é lissent. Getting clever about smart cities: new opportunities require new business models[J]. Cambridge, MA: Forrester Research 2010.
[9] A. Schlueter, P. Geyer, and S. Cisar, Analysis of geo-referenced building data for the identification and evaluation of thermal microgrids[J].Proc. IEEE,2016,4(104):45-47.
[10] Abdellah Chehri,Hussein.T.Mouftah. Service-oriented architecture for smart building energy management[C].IEEE International Conference on Communications.IEEE,2013,23(07): 4099-4103.
[11] Pan T S,Dao T K,Nguyen T T. A communication strategy for Paralleling grey wolf optimizer[M].//Genetic and Evolutionary Computing. Spring International Publishing,2015,27(10) 253—262.
[12] 郭振洲,刘 然,拱长青,等.基于灰狼算法的改进研究[J].计算机应用研究,2017,34(12):3603—3606.

作者简介

陈维华(1978-),女,硕士 ,教授。研究领域:物联网技术及应用。
张 苑(1990-),女,硕士, 讲师。研究领域:物联网技术及应用。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net