计算机应用研究
Application Research of Computers
ISSN 1001-3695,CN 51-1196/TP

《计算机应用研究》网络首发论文

题目：　一种低复杂度的鲁棒自适应波束形成算法
作者：　姚昊，武岳
DOI：　10.19734/j.issn.1001-3695.2022.03.0154
收稿日期：　2022-03-15
网络首发日期：　2022-06-23
引用格式：　姚昊，武岳．一种低复杂度的鲁棒自适应波束形成算法[J/OL]．计算机应用研究. https://doi.org/10.19734/j.issn.1001-3695.2022.03.0154

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2022-06-23 15:06:53
网络首发地址：https://kns.cnki.net/kcms/detail/51.1196.TP.20220622.0931.004.html

一种低复杂度的鲁棒自适应波束形成算法 *

姚 昊，武 岳†

(四川大学 计算机学院，成都 610041)

摘 要：传统的基于干扰噪声协方差矩阵(interference-plus-noise covariance matrix，INCM)重构的鲁棒自适应波束形成(robust adaptive beamformer，RAB)算法在多种样本数据协方差矩阵误差和信号导向向量误差的失配环境中具有较强的鲁棒性，但目前主流的 INCM 重构法都是对信号和干扰的导向向量通过建立凸优化模型来估计，这带来了很高的计算复杂度。为了解决这个问题，提出了一种低复杂度的基于 INCM 重构的 RAB 算法。该算法首先将干扰信号的导向向量分解为对应标称项和误差项的和，然后通过一种子空间方法估计得到误差项的单位向量。接下来对一个 Capon 空间谱功率最大问题进行求解，得到误差项的模值，以此得到重构的 INCM。同时利用 Capon 空间谱中残差噪声的存在，使用交替投影法估计得到期望信号的导向向量，最后得到所提出算法的权重向量。仿真实验表明所提出的算法在多种误差环境下具有较强鲁棒性的同时，还具有较低的计算复杂度。

关键词：协方差矩阵重构；特征分解；鲁棒自适应波束成形；导向向量估计

中图分类号：TN911.7 doi: 10.19734/j.issn.1001-3695.2022.03.0154

Novel robust adaptive beamforming with low complexity cost

Yao Hao, Wu Yue†

(*Sichuan University*, *College of Computer Science*, *Chengdu* 610041, *China*)

Abstract: The traditional robust adaptive beamforming (RAB) algorithm based on interference-plus-noise covariance matrix (INCM) reconstruction has strong robustness in many mismatched environment with sample data covariance matrix errors and signal steering vector errors. However, the current main methods of INCM reconstruction estimate the steering vector of signal and interference by establishing convex optimization model, which leads to high computation complexity. To solve this problem, this paper proposed a RAB algorithm based on INCM reconstruction with low computation complexity. Firstly, the steering vector of interference signal can be divided into two parts, namely the nominal vector and the mismatch vector. Then the unit vector of the mismatch vector can be estimated based on a subspace method. Then it got its norm via solving a Capon spectrum power maximization problem. Afterwards, it got its norm via solving a Capon spectrum power maximization problem to reconstruct the INCM. Meanwhile, using the existence of residual noise in the Capon spatial spectrum, it could estimate the steering vector of desired signal by the alternating projection algorithm, and finally obtain the weight vector of the proposed method. Simulations demonstrate the robustness of the proposed RAB algorithm at a cost of low computational complexity in cases of various mismatches.

Key words: covariance matrix reconstruction； eigenvalue decomposition；robust adaptive beamforming；steering vector estimation

0 引言

自适应波束形成算法被广泛应用于雷达和声纳，MIMO 无线通信，目标检测等领域[1]，其旨在对指定方向上的期望信号进行维持或者加强，并抑制其他方向上的干扰信号和噪声。然而在现实系统中，由于诸如信号的快拍数、阵列几何结构、DOA 方向等先验信息的缺失，以最小方差无失真响应(minimum variance distortionless response，MVDR)为代表的传统自适应波束形成性能会大幅度下降[2]。

为了弥补这个缺点，出现了许多对 RAB 的研究。其中最著名的要属对角加载技术 [3]，即对给样本数据协方差矩阵的对角元素增加一个相同的系数，以降低小样本下样本数据协方差矩阵估计不准的影响。这种方法最大的缺点在于该系数是一个经验值，难以确定。考虑到这点，出现了基于不确定集的方法，如最差情况性能最优方法[4]、双约束鲁棒 capon 波束形成器[5]等，将对 DL 系数的选取转换为对不确定集约束的选取，但这也并没有改变需要人为设置参数的本质。为了解决这个问题，上述的两种模型有诸多变体，比如文献[6]提出了一种自适应估计误差范数上界的方法。除此之外，基于不确定集的方法一般要求解一个凸/非凸优化问题，这导致了较高的计算复杂度。而作为另一种经典的 RAB 方法，收缩法认为单纯的对角加载技术欠缺对样本数据协方差矩阵权重的考虑，所以使用最小化 MSE 的方式以自适应得到两个对角系数[7]。除此之外，基于特征空间的方法[8]也对任意的导向向

收稿日期：2022-03-15；**修回日期：**2022-05-20 **基金项目：**成都市科技局重点研发支撑计划资助项目(2019-YF05-00998-SN)

作者简介：姚昊(1996-)，男，浙江湖州人，硕士研究生，主要研究方向为阵列处理、波束形成;武岳(1982-)，男(通信作者)，四川成都人，教授，博导，博士，主要研究方向为阵列信号处理、统计信号处理、智能信息获取与处理、声信号处理、无线传感网、无线通信(ivan.wuyue@scu.edu.cn).

量误差有不错的鲁棒性，但在低 SNR 情况下，由于信噪子空间难以分离，其鲁棒性会严重下降。

以上的方法并没有改变一个事实，即所使用的协方差矩阵依然是样本数据协方差矩阵或者其变体。所以在信号的导向向量出现误差的场景下，当期望信号的 SNR 较高时，传统的 RAB 算法会将期望信号当成干扰进行抑制[9]，这严重制约了传统 RAB 算法的性能。为了改变这一点，越来越多的工作将目光投放到重构干扰噪声协方差矩阵(INCM)上，这能直接解决期望信号在样本中存在的问题。Gu 等人[11]首先提出对干扰和噪声所在区间进行 Capon 空间谱积分来重构 INCM。基于他们的工作，Huang 等人[12]通过对干扰信号的导向向量的环状表面进行积分来进一步提高积分域的准度，带来更高性能的同时也导致了更高的复杂度。

但这带来一个问题，由于早期的 INCM 重构法是先重构 INCM，再利用重构后的 INCM 来估计信号的导向向量，所以无法保证重构时所使用的导向向量预估计值的精度。所以近几年来出现了一种先估计导向向量，再来重构 INCM 的技术路线[9,13~19]。比如文献[8]使用交替投影法，将干扰的导向向量估计为子空间的交集，该算法在大部分误差环境下鲁棒性很强，并具有较低的时间复杂度，是目前较为成熟的一种 RAB 设计。Zheng 等人[13]首次将基于不确定集的波束形成法运用于干扰的导向向量估计，开创了构建凸优化模型来解导向向量的先河。Zhu 等人[14]首次提出 Capon 空间谱中存在残差噪声这一概念，通过将其去除可以提高信号功率估计的精度，并在后续的工作[15]中将残差噪声重构的 INCM 用于建立关于干扰信号导向向量的凸优化模型，得到了更精准的结果。文献[16]将残差噪声与特征子空间结合起来，得到了一种快速但性能较差的方法。Sun 等人[17]提出了一种基于子空间梯度向量的方法去估计所有信号导向向量的误差向量。Chen 等人[18]直接通过一种不确定集压缩方法来估计 INCM 的误差矩阵。

Zheng 等人[19]整理了近几年 INCM 重构法的研究现状，其中上述介绍的第二条技术路线已经成为了 INCM 重构法的主流。但也存在着一些问题，比如对于导向向量估计往往是去估计其误差项的，误差项的估计法主要有两种，一种是基于优化模型的方法，一种是谱遍历的方法，这两种都需要人为设置区间参数的方法。如果在一个误差未知的环境下，其不具备鲁棒性。而 Huang[20]介绍了多种自适应的估计导向向量的方法，但由于其实现往往是解一个非凸优化模型，复杂度较高，实用性并不是很强。

针对上述的问题，本文设计出了提出了一种基于 INCM 重构的 RAB 算法，可以自适应的估计导向向量误差项的区间范围，通过谱遍历的方法得到其最优估计。

1　阵列模型

假设一共有 J+1 个远场平稳窄带信号以各自的 DOA 方向入射到阵列，其中包含 1 个期望信号和 J 个干扰信号，信号之间两两不相关。阵列由 M 个同向阵元组成。阵列的接受信号可以表述为

$$\boldsymbol{x}(t)=\boldsymbol{a}(\theta_0)s_0(t)+\sum_{j=1}^{J}\boldsymbol{a}(\theta_j)s_j(t)+\boldsymbol{n}(t) \tag{1}$$

其中 $\boldsymbol{a}(\cdot)$ 表示信号的真实导向向量，$\boldsymbol{n}(t)$ 是与期望信号和干扰信号无关的噪声。波束形成器的输出可以表示为

$$\boldsymbol{y}(t)=\boldsymbol{w}^H\boldsymbol{x}(t) \tag{2}$$

其中 $\boldsymbol{w}\in\mathbb{C}^{M\times 1}$ 表示波束形成器的加权向量。

如果 $\boldsymbol{a}(\theta_0)$ 精确已知，则 $\boldsymbol{w}_{opt}$ 可以通过最大化阵列的输出信干噪比(signal-to-interference-plus-noise ratio，SINR)来得到，SINR 的定义如下

$$\mathrm{SINR}_{\mathrm{out}}(\boldsymbol{w})=\frac{\mathbb{E}\{|\boldsymbol{w}^H\boldsymbol{x}_s(t)|^2\}}{\mathbb{E}\{|\boldsymbol{w}^H(\boldsymbol{x}_i(t)+\boldsymbol{x}_n(t))|^2\}}=\frac{\sigma_0^2|\boldsymbol{w}^H\boldsymbol{a}(\theta_0)|^2}{\boldsymbol{w}^H\boldsymbol{R}_{i+n}\boldsymbol{w}} \tag{3}$$

其中 $\boldsymbol{R}_{i+n}$ 就是 INCM，其定义如下

$$\begin{aligned}\boldsymbol{R}_{i+n}=&\ \mathbb{E}\{(\boldsymbol{x}_i(t)+\boldsymbol{n}(t))(\boldsymbol{x}_i(t)+\boldsymbol{n}(t))^H\}=\\&\sum_{j=1}^{J}\sigma_j^2\boldsymbol{a}(\theta_j)\boldsymbol{a}^H(\theta_j)+\sigma_n^2\boldsymbol{I}_M\end{aligned} \tag{4}$$

其中 $\sigma_j^2=\mathbb{E}\{|s_j(t)|^2\}$ 表示对应信号的功率，σ_n^2 则是噪声功率。

根据最大化式(3)得到的波束形成器就是著名的 MVDR 波束形成器

$$\boldsymbol{w}=\frac{\boldsymbol{R}_{i+n}^{-1}\boldsymbol{a}(\theta_0)}{\boldsymbol{a}(\theta_0)^H\boldsymbol{R}_{i+n}^{-1}\boldsymbol{a}(\theta_0)} \tag{5}$$

对应的 $\mathrm{SINR}_{\mathrm{opt}}$ 为

$$\mathrm{SINR}_{\mathrm{opt}}=\sigma_0^2\boldsymbol{a}^H(\theta_0)\boldsymbol{R}_{i+n}^{-1}\boldsymbol{a}(\theta_0) \tag{6}$$

另外根据文献[2]，如果 $\boldsymbol{a}(\theta_0)$ 精确已知，将式(5)中的 $\boldsymbol{R}_{i+n}$ 替换为 $\boldsymbol{R}:=\mathbb{E}\{\boldsymbol{x}(t)\boldsymbol{x}^H(t)\}$，其结果不变。而又由于实际系统中，$\boldsymbol{R}$ 是理论值，难以获得，所以一般用作为统计值的样本协方差矩阵 $\hat{\boldsymbol{R}}=\frac{1}{K}\sum_{k=1}^{K}\boldsymbol{x}(k)\boldsymbol{x}^H(k)$ 去代替。同理，真实的 $\boldsymbol{a}(\theta_0)$ 往往会受到许多干扰因素影响，比如 DOA 的失配、阵列精度失准等，需要用一个预估计值 $\bar{\boldsymbol{a}}(\hat{\theta}_0)$ 去代替，其中 $\bar{\boldsymbol{a}}(\cdot)$ 表示假设的期望信号关于已知阵列的导向向量，$\hat{\theta}_0$ 是估计的期望信号的 DOA。

基于上述的假设，式(5)有了更一般的表达

$$\boldsymbol{w}_{\mathrm{SMI}}=\frac{\hat{\boldsymbol{R}}^{-1}\bar{\boldsymbol{a}}(\hat{\theta}_0)}{\bar{\boldsymbol{a}}^H(\hat{\theta}_0)\hat{\boldsymbol{R}}^{-1}\bar{\boldsymbol{a}}(\hat{\theta}_0)} \tag{7}$$

这就是著名的样本协方差矩阵求逆(sample matrix inversion，SMI)法。然而，当样本的快拍数小时，$\hat{\boldsymbol{R}}$ 不会收敛到 $\boldsymbol{R}$。并且当 $\hat{\theta}_0$ 估计不准时，使用 $\hat{\boldsymbol{R}}$ 反而会压制期望信号，尤其是在信号的 SNR 较高时。

注意导向向量会做范数假设，即 $\|\boldsymbol{a}(\cdot)\|=M$ 。

2　算法模型

2.1　干扰信号的导向向量估计

干扰信号的 DOA 估计有多种方法，这里使用最基础的谱峰搜索法：

$$\hat{\theta}_j=\arg\max_{\theta\in\Theta_j}\left\{\frac{1}{\bar{\boldsymbol{a}}^H(\theta)\hat{\boldsymbol{R}}^{-1}\bar{\boldsymbol{a}}(\theta)}\right\} \tag{8}$$

其中即在信号 j 的假设 DOA 区间 Θ_j 上找到最大的 Capon 空间谱谱峰所对应的横坐标。得到估计的 DOA 之后，信号 j 的真实导向向量 $\boldsymbol{a}(\theta_j)$，可以拆成理论项和误差项的和，即

$$\boldsymbol{a}(\theta_j)=\bar{\boldsymbol{a}}(\hat{\theta}_j)+\boldsymbol{e}_j \tag{9}$$

其中 $\boldsymbol{e}_j$ 又可以分成 $\bar{\boldsymbol{a}}(\hat{\theta}_j)$ 的平行分量和垂直分量

$$\boldsymbol{e}_j=\boldsymbol{e}_{j,\|}+\boldsymbol{e}_{j,\perp} \tag{10}$$

根据式(3)的定义可知，$\boldsymbol{w}$ 的任意常数倍不会影响阵列的输出 SINR，即 $\boldsymbol{e}_{j,\|}$ 的存在不会影响 RAB 的性能。所以 $\boldsymbol{e}_{j,\perp}$ 可以视为真实误差项的一种估计，即有 $\hat{\boldsymbol{e}}_j\approx\boldsymbol{e}_{j,\perp}=\varepsilon_j\boldsymbol{v}_j$，其中 ε_j 是 $\boldsymbol{e}_{j,\perp}$ 的模，是未知量，$\boldsymbol{v}_j$ 是 $\boldsymbol{e}_{j,\perp}$ 的单位向量。

根据文献[21]定义子空间 $\boldsymbol{C}_j$ 如下

$$\boldsymbol{C}_j=\int_{\hat{\theta}_j-\frac{\Delta\theta}{2}}^{\hat{\theta}_j+\frac{\Delta\theta}{2}}\bar{\boldsymbol{a}}(\theta)\bar{\boldsymbol{a}}^H(\theta)\mathrm{d}\theta \tag{11}$$

其中 $\Delta\theta$ 是 Θ_j 的大小。$\boldsymbol{C}_j$ 可以理解为假设的信号 j 所在区间上所有导向向量撑起的子空间。对 $\boldsymbol{C}_j$ 进行特征分解，得

$$\boldsymbol{C}_j=\sum_{m=1}^{M}\lambda_{j,m}\boldsymbol{u}_{j,m}\boldsymbol{u}_{j,m}^H \tag{12}$$

其中 $\lambda_{j,1}\ge\lambda_{j,2}\ge\ldots\ge\lambda_{j,M}$ 是 $\boldsymbol{C}_j$ 降序排列的特征值，$\boldsymbol{u}_{j,M}$ 是对应的特征向量。由于信号子空间和噪声子空间正交的性质，真实的 $\boldsymbol{a}(\theta_j)$ 会正交于 $\boldsymbol{C}_j$ 的噪声子空间，即其非主特征值对应的特征向量所组成的矩阵。那么可以将最小的特征向量 $\boldsymbol{u}_{j,M}$ 当成是 $\boldsymbol{v}_j$ 的粗略估计，即 $\boldsymbol{v}_j\approx\boldsymbol{u}_{j,M}$。这样 $\boldsymbol{a}(\theta_j)$ 的估计值可以表示为

$$\begin{aligned}\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j)&=\frac{M^{\frac{1}{2}}\left(\bar{\boldsymbol{a}}(\hat{\theta}_j)+\varepsilon_j\boldsymbol{u}_{j,M}\right)}{\|\bar{\boldsymbol{a}}(\hat{\theta}_j)+\varepsilon_j\boldsymbol{u}_{j,M}\|_2}=\\&\left(\frac{M}{M+\varepsilon_j^2}\right)^{\frac{1}{2}}\left(\bar{\boldsymbol{a}}(\hat{\theta}_j)+\varepsilon_j\boldsymbol{u}_{j,M}\right)\end{aligned} \tag{13}$$

显然，当估计值 $\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j)$ 估计得越准确，即越接近真实值 $\boldsymbol{a}(\theta_j)$，其 Capon 空间谱功率越大。所以有以下的关系

$$\frac{1}{\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j)\hat{\boldsymbol{R}}^{-1}\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j)}\ge\frac{1}{\bar{\boldsymbol{a}}^H(\hat{\theta}_j)\hat{\boldsymbol{R}}^{-1}\bar{\boldsymbol{a}}(\hat{\theta}_j)} \tag{14}$$

不等式的左边是 $\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j)$ 的 Capon 空间谱功率 $P(\hat{\theta}_j,\varepsilon_j)$，右边是 $\bar{\boldsymbol{a}}(\hat{\theta}_j)$ 的 Capon 空间谱功率 $P(\hat{\theta}_j)$。将式(13)带入式(14)的约束不等式可得

$$\begin{aligned}&\bar{\boldsymbol{a}}^H(\hat{\theta}_j)\hat{\boldsymbol{R}}^{-1}\bar{\boldsymbol{a}}(\hat{\theta}_j)\le\\&\left(\frac{M}{M+\varepsilon_j^2}\right)\left(\bar{\boldsymbol{a}}(\hat{\theta}_j)+\varepsilon_j\boldsymbol{u}_{j,M}\right)^H\hat{\boldsymbol{R}}^{-1}\left(\bar{\boldsymbol{a}}(\hat{\theta}_j)+\varepsilon_j\boldsymbol{u}_{j,M}\right)\end{aligned} \tag{15}$$

为了公式表述得更清楚，定义一些标量

$$f_{\bar{a},\bar{a}}=\bar{\boldsymbol{a}}^H(\hat{\theta}_j)\hat{\boldsymbol{R}}^{-1}\bar{\boldsymbol{a}}(\hat{\theta}_j) \tag{16}$$

$$f_{\boldsymbol{u},\boldsymbol{u}}=\boldsymbol{u}_{j,M}^H\hat{\boldsymbol{R}}^{-1}\boldsymbol{u}_{j,M} \tag{17}$$

$$f_{\bar{a},\boldsymbol{u}}=\Re\left\{\bar{\boldsymbol{a}}^H(\hat{\theta}_j)\hat{\boldsymbol{R}}^{-1}\boldsymbol{u}_{j,M}\right\} \tag{18}$$

因此，式(15)可以化简为

$$\left(f_{\boldsymbol{u},\boldsymbol{u}}-\frac{f_{\bar{a},\bar{a}}}{M}\right)\varepsilon_j^2+2f_{\bar{a},\boldsymbol{u}}\,\varepsilon_j\le 0 \tag{19}$$

因为 $\hat{\boldsymbol{R}}$ 是 Hermitian 矩阵，所以 $f_{\bar{a},\bar{a}}$ 和 $f_{\boldsymbol{u},\boldsymbol{u}}$ 都是正数。同时，$f_{\bar{a},\bar{a}}$ 的倒数表示的是 $\bar{\boldsymbol{a}}(\hat{\theta}_j)$ 的 Capon 空间谱谱峰，显然有 $f_{\bar{a},\bar{a}}<f_{\boldsymbol{u},\boldsymbol{u}}$，所以 $f_{\boldsymbol{u},\boldsymbol{u}}-\frac{f_{\bar{a},\bar{a}}}{M}>0$。因此，$\varepsilon_j$ 的支撑集 S 可以表示为

$$\varepsilon_j\in\begin{cases}\left[0,\dfrac{-2f_{\bar{a},\boldsymbol{u}}}{f_{\boldsymbol{u},\boldsymbol{u}}-\dfrac{f_{\bar{a},\bar{a}}}{M}}\right] & f_{\bar{a},\boldsymbol{u}}<0\\ 0 & f_{\bar{a},\boldsymbol{u}}=0\\ \left[\dfrac{-2f_{\bar{a},\boldsymbol{u}}}{f_{\boldsymbol{u},\boldsymbol{u}}-\dfrac{f_{\bar{a},\bar{a}}}{M}},0\right] & f_{\bar{a},\boldsymbol{u}}>0\end{cases} \tag{20}$$

所以可以通过遍历集合 S 来找到使对应的 Capon 空间谱功率得到最大值的 ε_j 的最优值 ε_j^*

$$\varepsilon_j^*=\arg\max_{\varepsilon_j\in S}\frac{1}{\hat{\boldsymbol{a}}^H(\theta_j,\varepsilon_j)\hat{\boldsymbol{R}}^{-1}\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j)} \tag{21}$$

2.2　期望信号导向向量估计

对样本协方差矩阵 $\hat{\boldsymbol{R}}$ 进行特征分解有

$$\hat{\boldsymbol{R}}=\sum_{m=1}^{M}\lambda_m\boldsymbol{u}_m\boldsymbol{u}_m^H=\boldsymbol{U}_s\boldsymbol{\Lambda}_s\boldsymbol{U}_s^H+\boldsymbol{U}_n\boldsymbol{\Lambda}_n\boldsymbol{U}_n^H \tag{22}$$

其中 $\{\lambda_m\}_{m=1}^M$ 是 $\hat{\boldsymbol{R}}$ 单调递减的特征值，$\boldsymbol{u}_m$ 是对应的特征向量。$\boldsymbol{U}_s=[\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_{J+1}]$ 为前 J+1 个主特征向量组成的子集合，$\boldsymbol{\Lambda}_s$ 为前 J+1 个主特征向量组成的对角阵，Span$\{\boldsymbol{U}_s\}$ 为 $\boldsymbol{U}_s$ 的列向量张成的信号子空间。同理噪声子空间就是 Span$\{\boldsymbol{U}_n\}$。根据文献[19]，真实期望信号的导向向量 $\boldsymbol{a}(\theta_0)$ 位于 Span$\{\boldsymbol{U}_s\}$ 中。

另外，根据文献[22]，$\boldsymbol{a}(\theta_0)$ 同样位于导向向量的预估计值的 Capon 空间谱积分所重构的信号协方差矩阵 $\hat{\boldsymbol{R}}_s$ 的信号子空间中，其中 $\hat{\boldsymbol{R}}_s$ 可以通过对包括期望信号和干扰信号的区间 Θ_s 上的 Capon 空间谱积分得到

$$\hat{\boldsymbol{R}}_s=\int_{\Theta_s}\frac{1}{\bar{\boldsymbol{a}}(\theta)\hat{\boldsymbol{R}}\bar{\boldsymbol{a}}^H(\theta)}\bar{\boldsymbol{a}}(\theta)\bar{\boldsymbol{a}}^H(\theta)\mathrm{d}\theta \tag{23}$$

如果把 $P(\theta)=\frac{1}{\bar{\boldsymbol{a}}(\theta)\hat{\boldsymbol{R}}\bar{\boldsymbol{a}}^H(\theta)}$ 直接作为 $\bar{\boldsymbol{a}}(\theta)$ 空间谱功率的估计，当信号快拍数较小时，$\hat{\boldsymbol{R}}_s$ 与理论值 $\boldsymbol{R}_s$ 会有较大的差距。Zhu 等人[14,15]认为是 $P(\theta)$ 中除了信号功率，还存在着残差噪声，它可以近似为只包括噪声的区间 Θ_n 上的平均功率

$$\bar{\sigma}_n^2=\frac{1}{T}\sum_{t=1}^{T}\frac{1}{\bar{\boldsymbol{a}}(\theta_t)\hat{\boldsymbol{R}}^{-1}\bar{\boldsymbol{a}}^H(\theta_t)},\quad\theta\in\Theta_n \tag{24}$$

其中 T 是 Θ_n 上的采样点个数，θ_t 是离散的采样点。

所以可以得到更精确的信号协方差矩阵

$$\tilde{\boldsymbol{R}}_s=\int_{\Theta_s}[P(\theta)-\bar{\sigma}_n^2]\bar{\boldsymbol{a}}(\theta)\bar{\boldsymbol{a}}^H(\theta)\mathrm{d}\theta \tag{25}$$

类似式(13)对 $\tilde{\boldsymbol{R}}_s$ 进行特征分解得到

$$\tilde{\boldsymbol{R}}_s=\sum_{m=1}^{M}\mu_m\boldsymbol{v}_m\boldsymbol{v}_m^H \tag{26}$$

其中 $\{\mu_m\}_{m=1}^M$ 是单调递减的特征值，$\boldsymbol{v}_m$ 是对应的特征向量。可以类似文献[13]那样通过设置一个边界阈值来得到此时的主特征值数量 L

$$\min_L\left(\frac{\sum_{j=1}^{L}|\mu_j|^2}{\sum_{j=1}^{M}|\mu_j|^2}\right)>\xi \tag{27}$$

然后构建前 L 个主特征向量组成的子集合 $\boldsymbol{V}=[\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_L]$，所以新的信号子空间就为 Span$\{\boldsymbol{V}\}$。根据上述的讨论，$\boldsymbol{a}(\theta_0)$ 位于 Span$\{\boldsymbol{U}_s\}$ 和 Span$\{\boldsymbol{V}\}$ 两个子空间的交集上，即

$$\boldsymbol{a}(\theta_0)\in\mathrm{Span}\{\boldsymbol{U}_s\}\cup\mathrm{Span}\{\boldsymbol{V}\} \tag{28}$$

基于交替投影理论[23]，可以得到 $\boldsymbol{a}(\theta_0)$ 的迭代表达式

$$\boldsymbol{a}_0^{n+1}=\boldsymbol{P}_u\boldsymbol{P}_v\boldsymbol{a}_0^n \tag{29}$$

其中 $\boldsymbol{a}_0^n$ 表示第 n 次迭代中的 $\boldsymbol{a}(\theta_0)$ 估计值，两个子空间的投影算子分别为 $\boldsymbol{P}_u=\boldsymbol{U}_s\boldsymbol{U}_s^H$ 和 $\boldsymbol{P}_v=\boldsymbol{V}\boldsymbol{V}^H$。当 $n\to\infty$，$\boldsymbol{a}_0^n$ 会收敛于 $\boldsymbol{a}(\theta_0)$。

可以发现，式(29)就是一个 Markov 模型，其中 $\boldsymbol{P}_u\boldsymbol{P}_v$ 就是一个 Markov 矩阵。因此，最终的稳定状态就是 $\boldsymbol{P}_u\boldsymbol{P}_v$ 矩阵的最大特征值对应的特征向量[24]。所以 $\boldsymbol{a}(\theta_0)$ 的估计值可以表示为

$$\hat{\boldsymbol{a}}(\theta_0)=\sqrt{M}\,\mathcal{P}\{\boldsymbol{P}_u\boldsymbol{P}_v\} \tag{30}$$

2.3　重构 INCM

根据 2.2 节，得到 ε_j^* 之后，对应的干扰信号的导向向量的最优估计 $\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j^*)$ 可以由式(12)得到。这样，INCM 就可以由 $\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j^*)$ 和对应的 Capon 空间谱功率的加权得到：

$$\hat{\boldsymbol{R}}_{i+n}=\sum_{j=1}^{J}\frac{\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j^*)\hat{\boldsymbol{a}}^H(\theta_j,\varepsilon_j^*)}{\hat{\boldsymbol{a}}^H(\theta_j,\varepsilon_j^*)\hat{\boldsymbol{R}}^{-1}\hat{\boldsymbol{a}}(\theta_j,\varepsilon_j^*)}+\hat{\sigma}_n^2\boldsymbol{I}_M \tag{31}$$

其中 $\boldsymbol{I}_M$ 是 M 维的单位矩阵，噪声的功率 $\hat{\sigma}_n^2$ 可以通过残差噪声功率 $\bar{\sigma}_n^2$ 得到

$$\hat{\sigma}_n^2=M\bar{\sigma}_n^2 \tag{32}$$

2.4　得到波束形成器的加权向量

得到期望信号的导向向量的估计和重构的 INCM 后，根据式(5)得到所求的加权向量 $\boldsymbol{w}$：

$$\boldsymbol{w}_{\mathrm{PRO}}=\frac{\hat{\boldsymbol{R}}_{i+n}^{-1}\hat{\boldsymbol{a}}(\theta_0)}{\hat{\boldsymbol{a}}^H(\theta_0)\hat{\boldsymbol{R}}_{i+n}^{-1}\hat{\boldsymbol{a}}(\theta_0)} \tag{33}$$

2.5　时间复杂度分析

所提出的 RAB 算法中，主要的时间复杂度为特征向量分解和 ε_j 的遍历。前者时间复杂度是 $\mathcal{O}(JM^3)$，后者时间复杂度是 $\mathcal{O}(NM^3)$。J 是信号个数，M 是阵元个数，N 是采样点个数。所以最终的时间复杂度就是 $\mathcal{O}(\max(J,N)M^3)$。

3　实验仿真

3.1　实验设置

仿真的信号都是远场窄带平面波。阵列是由 10 个阵元组成的均匀线阵(uniform linear array，ULA)，阵元间距是信号波长的一半。一共有三个信号入射到该阵列上，其中期望信号的真实 DOA $\theta_0=3^\circ$，两个干扰信噪比(interference-to-noise，INR)都是 20dB 的干扰信号的真实 DOA 分别为 $\theta_1=-30^\circ$ 和 $\theta_2=40^\circ$。但关于信号和干扰的 DOA 先验信息未知，所以假设入射方向为 $\bar{\theta}_0=5^\circ$，$\bar{\theta}_1=-33^\circ$ 和 $\bar{\theta}_2=37^\circ$。噪声是一个具有零均值和单位方差的时空对称复高斯过程。并假设期望信号的 DOA 所在区间 $\Theta_s=[\bar{\theta}_0-8^\circ,\bar{\theta}_0+8^\circ]$，干扰的 DOA 所在区间 $\Theta_i=\Theta_1\cup\Theta_2=[\bar{\theta}_1-8^\circ,\bar{\theta}_1+8^\circ]\cup[\bar{\theta}_2-8^\circ,\bar{\theta}_2+8^\circ]$，这些区间的角度间隔设为 0.5°。一共执行 100 次蒙特卡洛数值仿真。

控制变量分别为期望信号的 SNR 和样本快拍数的个数。使用阵列的输出 SINR 作为性能分析的参考。当使用 SNR 作为控制变量时，样本快拍数固定为 30 个；当使用样本快拍数作为控制变量时，SNR 固定为 10dB。作为对照的最优 SINR 使用式(6)得到。

提出的 RAB 算法一共与 7 种基于 INCM 重构的 RAB 算法进行对比：一种基于线性 Capon 空间谱积分估计 INCM 的方法(INCM-linear)[10]；一种基于环形表面积分估计干扰协方差矩阵的方法(INCM-annulus)[11]；一种使用 RCB 标准估计干扰导向向量的方法(INCM-RCB)[15]；一种利用求子空间交集以估计干扰导向向量的方法(INCM-subspace)[8]；一种基于干扰导向向量的梯度向量估计的方法(INCM-gradient)[16]；一种基于 INCM 误差矩阵收缩估计的方法(INCM-USS)[17]；一种使用残差噪声重构的 INCM 去估计干扰向量的方法(INCM-residual)[14]。

3.2　DOA 误差

在这里例子中，每次蒙特卡洛实验的期望信号和干扰信号的真实 DOA 是不同的，与 3.1 节中的 DOA 设置的真实值之间存在 $[-4^\circ,4^\circ]$ 的均分分布误差。

由图 1(a)和(b)可见，INCM-subspace、INCM-gradient、INCM-residual、INCM-USS 和 Proposed 这 5 种算法的性能明显强于 INCM-linear、INCM-annulus 和 INCM-RCB。并且 Proposed 在 SNR 大于-5dB 时，性能仅略输于 INCM-subspace。

图 1(c)说明除 INCM-RCB 之外，剩余 7 种都能快速收敛，并且 INCM-subspace、INCM-gradient、INCM-residual、INCM-USS 和 Proposed 这 5 种算法与理论最优值非常接近。

图 2 是关于期望信号在 DOA 误差范围 $[-4^\circ,4^\circ]$ 中固定 DOA 实验条件下各种 RAB 的性能对比图，其中期望信号的 SNR 为 10dB，快拍数为 30。从图中看出 INCM-subspace、INCM-gradient 和 Proposed 这三种 RAB 随 DOA 误差的增大 SINR 基本呈现一条直线，说明可以有效的对抗较大范围的 DOA 误差。

3.3　阵元间距误差

在这个实验中，作为仿真的阵元间距不再是固定值，实际值与理论值的误差服从 $[-0.05\lambda_s,0.05\lambda_s]$ 的均匀分布，其中 λ_s 为信号波长。

从图 3(a)看出，当 SNR 小于 6dB 时 INCM-RCB 明显优于其他的 RAB。但超过这个值，INCM-RCB 会性能下降。图 3(b)显示 INCM-gradient、INCM-subspace 和 Proposed 几乎性能一致，在较广的 SNR 域内能达到不错的性能。

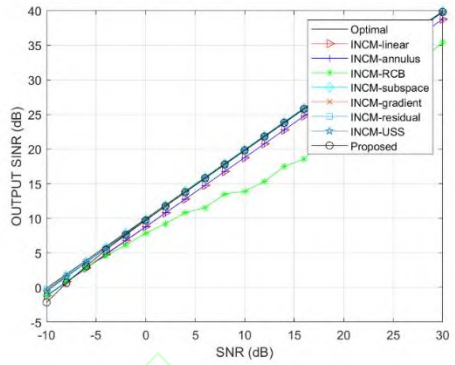

(a)输出 SINR 随输入 SNR 的变化

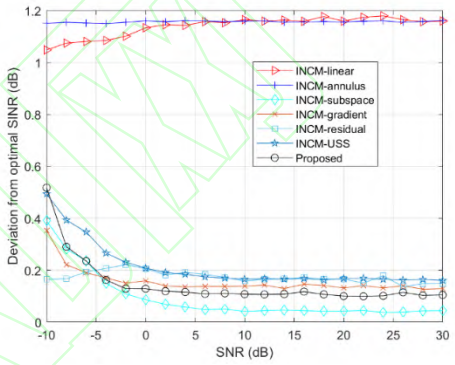

(b)与理论最优 SINR 之差随输入 SNR 的变化

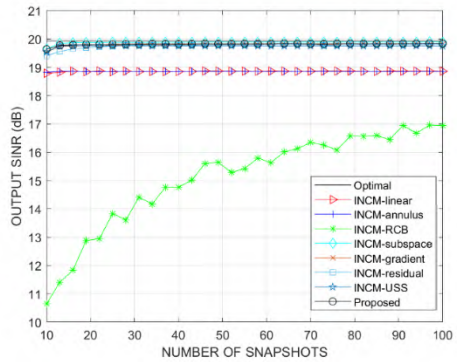

(c)输出 SINR 随快拍数的变化

图 1　DOA 误差场景下 RAB 算法的性能对比

Fig. 1　Performance comparison of RAB algorithms in the case of signal direction error

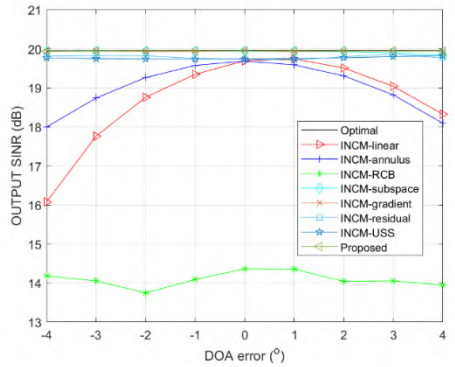

图 2　不同 DOA 误差角度对应的输出 SINR

Fig. 2　Output SINR versus DOA error

图 3(c) 显示 INCM-RCB 对快拍数更敏感，小样本情况下性能很差，但当快拍数足够大时，其性能会有较大的提升。除此之外的 RAB 都能快速收敛到一个稳定的状态，并且 INCM-linear、INCM-annulus、INCM-residual、INCM-subspace、INCM-gradient 和 Proposed 性能几乎相同，都能达到一个较优值。

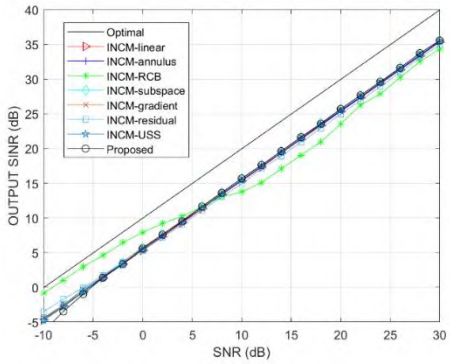

(a)输出 SINR 随输入 SNR 的变化

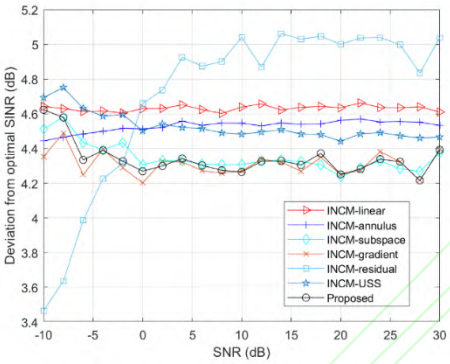

(b)与理论最优 SINR 之差随输入 SNR 的变化

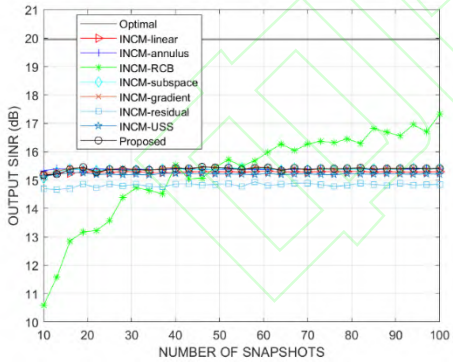

(c)输出 SINR 随快拍数的变化

图 3　存在阵元位置误差时的 RAB 性能对比

Fig. 3　Performance comparison of RAB algorithms in the case of sensor location error

3.4　阵列的增益和相位误差

在第三次实验中，阵列中每个阵元的增益和相位会出现误差，分别符合高斯分布 $\mathcal{N}(0,0.04^2)$ 和 $\mathcal{N}(0,(0.025\pi)^2)$ 。

该环境的误差于阵元间距误差类似，都属于阵列精度误差的一种。所以从图 4(a)和(b)可以发现，INCM-gradient、INCM-subspace 和 Proposed 依然能在较广的 SNR 域内达到相对较高的性能。图 4(c)显示这三种方法的 SINR 能快速收敛到稳定值，相对性能最优。

3.5　波束方向图

图 5 是在没有任何实际失配误差，先验信息全部已知的情况下，设置期望信号的 SNR 为 10dB，快拍数为 30，根据仿真实验中表现最为优秀的 INCM-gradient、INCM-subspace 和 Proposed 三种 RAB 对应的波束方向图：

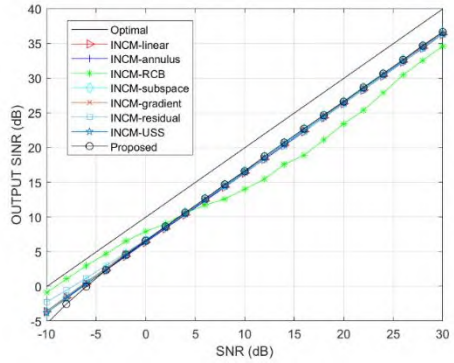

(a)输出 SINR 随输入 SNR 的变化

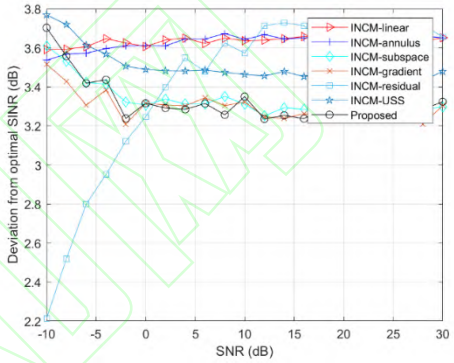

(b)与理论最优 SINR 之差随输入 SNR 的变化

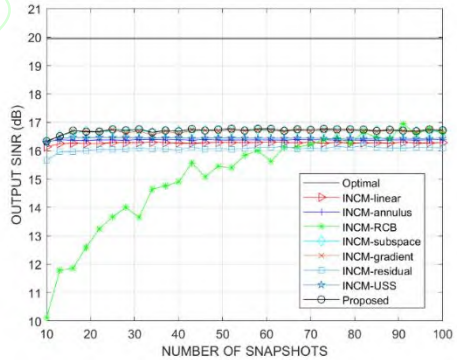

(c)输出 SINR 随快拍数的变化

图 4　存在阵元增益和相位误差时的 RAB 性能对比。

Fig. 4　Performance comparison in the case of gain and phase Error

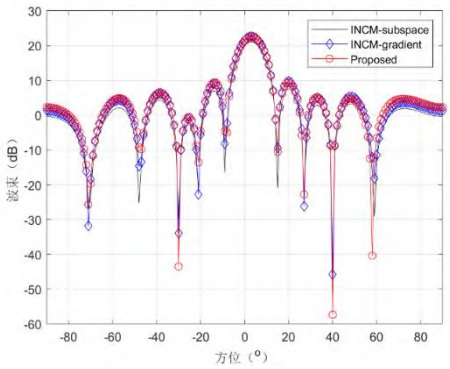

图 5　无偏情况下的波束方向图

Fig. 5　Beampatterns without bias

可以发现，这三种表现类似的方法都能形成对准期望信号方向的主瓣，且在干扰的方向上形成相应的零陷，从而完

成干扰抑制与不失真接受期望信号的任务。同时可以观察得到，这三种算法的主瓣宽度基本一致，但本文的方法的零陷深度明显最深，即抑制干扰能力更强。

3.6　运行时间比较

本文统计了上述 8 种 RAB 单次模拟的平均运行时间，如表 1 所示。所有的模拟实验都是在具有 24GB RAM 和 Intel(R) Core(TM) i7-8700 3.20 GHz 的同一台计算机上进行的。 在几种性能相似的 RAB 中，例如 INCM-subspace 和 INCM-gradient，可以看到本文的方法具有最小的计算复杂度。

表 1　RAB 单次蒙特卡洛仿真的平均运行时间

Tab. 1　Average Running Time of each RAB in one Monte Carlo Run

RAB	running time/s
INCM-linear	11.501
INCM-annulus	27.346
INCM-RCB	12.334
INCM-subspace	0.165
INCM-gradient	0.219
INCM-USS	0.823
INCM-residual	6.552
PROPOSED	0.069

4　结束语

本文提出了一种基于干扰信号导向向量估计的 INCM 重构法和一种基于残差噪声的期望信号导向向量估计法。前者是将实际干扰信号的导向向量拆成理论向量和误差向量之和，将对 INCM 的重构转换对干扰信号的误差向量的估计，并且通过求解最大化 Capon 空间谱功率得到了误差项模的最优估计。期望而通过残差噪声的去除，重构了期望信号的协方差矩阵，并通过一种基于子空间的方法估计出了期望信号。与现有方法相比，该方法几乎可以达到最佳的性能。同时，与其他性能相近的算法相比，该算法具有最小的计算量。

最后，由于大部分 RAB 算法的研究都是基于窄带信号，如何将算法推广到宽带信号场景是一个值得研究的方向。

参考文献：

[1] Swindlehurst A L, Jeffs B D, Seco-Granados G, *et al.* Applications of array signal processing [M]// Academic Press Library in Signal Processing. Elsevier, 2014, 3: 859-953.

[2] Van Trees H L. Optimum array processing: Part IV of detection, estimation, and modulation theory [M]. John Wiley & Sons, 2004.

[3] Cox H, Zeskind R, Owen M. Robust adaptive beamforming [J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1987, 35 (10): 1365-1376.

[4] 尹京升，王少强，王海斌. 可变不确定集约束的鲁棒自适应波束形成方法 [J]. 声学学报, 2021, 46 (06): 871-883. (Yin Jingsheng, Wang Shaoqiang, Wang Haibin. A robust adaptive beamforming method based on variable constraint of uncertainty set [J]. Acta Acustica, 2021, 46 (06): 871-883.)

[5] Vorobyov S A, Gershman A B, Luo Z Q. Robust adaptive beamforming using worst-case performance optimization: A solution to the signal mismatch problem [J]. IEEE transactions on signal processing, 2003, 51 (2): 313-324.

[6] Li J, Stoica P, Wang Z. Doubly constrained robust Capon beamformer [J]. IEEE Transactions on Signal Processing, 2004, 52 (9): 2407-2423.

[7] Du L, Li J, Stoica P. Fully automatic computation of diagonal loading levels for robust adaptive beamforming [J]. IEEE Transactions on Aerospace and Electronic Systems, 2010, 46 (1): 449-458.

[8] Feldman D D, Griffiths L J. A projection approach for robust adaptive beamforming [J]. IEEE Transactions on signal processing, 1994, 42 (4): 867-876.

[9] Yuan X, Gan L. Robust adaptive beamforming via a novel subspace method for interference covariance matrix reconstruction [J]. Signal Processing, 2017, 130: 233-242.

[10] Zheng Z, Yang T, Wang W Q, *et al.* Robust adaptive beamforming via simplified interference power estimation [J]. IEEE Transactions on Aerospace and Electronic Systems, 2019, 55 (6): 3139-3152.

[11] Gu Y, Leshem A. Robust adaptive beamforming based on interference covariance matrix reconstruction and steering vector estimation [J]. IEEE Transactions on Signal Processing, 2012, 60 (7): 3881-3885.

[12] Huang L, Zhang J, Xu X, *et al.* Robust adaptive beamforming with a novel interference-plus-noise covariance matrix reconstruction method [J]. IEEE Transactions on Signal Processing, 2015, 63 (7): 1643-1650.

[13] Zheng Z, Zheng Y, Wang W Q, *et al.* Covariance matrix reconstruction with interference steering vector and power estimation for robust adaptive beamforming [J]. IEEE Transactions on Vehicular Technology, 2018, 67 (9): 8495-8503.

[14] Zhu X, Ye Z, Xu X, *et al.* Covariance matrix reconstruction via residual noise elimination and interference powers estimation for robust adaptive beamforming [J]. IEEE Access, 2019, 7: 53262-53272.

[15] Zhu X, Xu X, Ye Z. Robust adaptive beamforming via subspace for interference covariance matrix reconstruction [J]. Signal Processing, 2020, 167: 107289.

[16] 陆家威，童晖，许伟杰. 稳健协方差矩阵重构波束形成算法 [J]. 声学技术, 2022, 41 (1): 131-136. (Lu Jiawei, Tong Hui, Xu Weijie. Robust adaptive beamforming based on covariance matrix reconstruction [J]. Technical Acoustics, 2022, 41 (1): 131-136.)

[17] Sun S, Ye Z. Robust adaptive beamforming based on a method for steering vector estimation and interference covariance matrix reconstruction [J]. Signal Processing, 2021, 182: 107939.

[18] Chen P, Yang Y. An uncertainty-set-shrinkage-based covariance matrix reconstruction algorithm for robust adaptive beamforming [J]. Multidimensional Systems and Signal Processing, 2021, 32 (1): 263-279.

[19] Zheng Z, Yang T, Wang W Q, *et al.* Robust adaptive beamforming via simplified interference power estimation [J]. IEEE Transactions on Aerospace and Electronic Systems, 2019, 55 (6): 3139-3152.

[20] Huang Y, Zhou M, Vorobyov S A. New designs on MVDR robust adaptive beamforming based on optimal steering vector estimation [J]. IEEE Transactions on Signal Processing, 2019, 67 (14): 3624-3638.

[21] Hassanien A, Vorobyov S A, Wong K M. Robust adaptive beamforming using sequential quadratic programming: An iterative solution to the mismatch problem [J]. IEEE Signal Processing Letters, 2008, 15: 733-736.

[22] Shen F, Chen F, Song J. Robust adaptive beamforming based on steering vector estimation and covariance matrix reconstruction [J]. IEEE Communications Letters, 2015, 19 (9): 1636-1639.

[23] Zhuang J, Manikas A. Interference cancellation beamforming robust to pointing errors [J]. IET Signal Processing, 2013, 7 (2): 120-127.

[24] Diaconis P, Stroock D. Geometric bounds for eigenvalues of Markov chains [J]. The annals of applied probability, 1991: 36-61